

AI交易引擎：机器学习交易策略与场景应用

TASK6 课程报告

姓名	_____
数据	股票财务指标 + Tushare季度末收盘价
模型	逻辑回归、决策树、随机森林
方法	扩展窗口训练 + 季度调仓样本外回测

报告摘要：基于20,733条股票一季度样本，衍生21项模型因子，并使用滚动样本外方法比较三类分类模型。逻辑回归样本外AUC为0.632，三季度累计收益为-3.0%，同期全市场等权为-19.8%。研究期处于整体下跌阶段，模型主要体现为减亏和排序能力。

1 基于机器学习模型的交易策略核心理念

机器学习交易策略将金融数据转换为可学习的特征，以未来收益、涨跌方向或相对排名为目标，利用历史样本训练模型，再把预测概率映射为持仓、权重和调仓规则。其核心不是追求一次预测完全正确，而是在大量重复决策中获得具有统计优势的排序，并通过组合分散、成本控制和风险约束将弱信号转化为可执行策略。

1.1 主要优点

第一，能够同时处理估值、成长、质量、规模等多维信息；第二，树模型可捕捉非线性与变量交互；第三，研究流程可程序化复现，便于滚动更新和模型比较；第四，预测概率天然适合选股排序与仓位分层。

1.2 主要缺点

机器学习容易过拟合，历史关系还可能因市场制度、风格切换而漂移。若数据存在未来信息、退市样本遗漏或财务数据发布时间错位，回测会产生虚假优势。此外，换手、滑点、冲击成本和容量约束都会使实盘收益低于理想回测。

2 常见自变量因子与应变量定义

类型	典型指标	经济含义
估值因子	PE、PB、PS、PCF、EV/EBITDA	寻找相对便宜或定价偏低的股票
成长因子	收入、利润、EPS同比增长率	刻画企业扩张速度与盈利增量
质量因子	资产增长、现金流增长、盈利稳定性	衡量经营质量与财务可持续性
规模因子	总市值、流通市值	反映市值风格与流动性差异
交易因子	动量、波动率、成交量、换手率	反映价格趋势、风险与交易拥挤度
应变量	未来收益、超额收益、涨跌方向	本研究采用下一季度收益是否高于截面中位数

本研究定义：对每个季度内的原始财务指标进行1%—99%缩尾和横截面百分位排名，再构造价值、成长、质量和规模合成因子，共形成21项自变量。下一季度简单价格收益高于当季股票截面中位数记为Y=1，否则记为Y=0；模型输出Y=1的预测概率。

3 数据、变量衍生与样本划分

财务样本覆盖2021年6月至2022年6月的5个季度末，原始数据为20,772行。将证券代码映射为交易所代码，与Tushare季度末收盘价匹配后得到20,733条可用样本、4,280只股票。收益口径为相邻季度末收盘价之比减1，未计股息与复权，因此属于教学性简单价格收益。为降低极端公司行为对等权组合均值的支配，回测收益按季度截面0.5%和99.5%分位缩尾。

3.1 时间序列划分

采用扩展窗口而非随机切分：测试2021年12月时只使用此前两个季度训练；测试2022年3月时加入2021年12月以前样本；测试2022年6月时继续扩展训练集。该设置保证每次预测均不使用未来信息，并将三期样本外预测拼接评价。




图1 各季度模型标签分布

图形解读：标签由每期收益中位数定义，因此Y=0与Y=1基本各占一半，能够降低类别失衡对准确率的误导。

3.2 关键 Python 实现

```
data['target'] = (data['forward_return'] > median_return).astype(int)
test_dates = dates[-3:] # ■■■■■■■■
selected = test.nlargest(int(len(test) * 0.20), 'probability')
net_return = gross_return - turnover * 0.001
```

4 模型构建与分类效果

逻辑回归作为可解释的线性基准，先标准化后训练；决策树限制最大深度并提高叶节点最小样本数，以控制过拟合；随机森林使用400棵树、特征随机抽样和类别平衡权重，以集成方式降低单树方差。三个模型均使用相同训练期、特征和测试期。

模型	AUC	准确率	Precision	Recall	F1
逻辑回归	0.632	0.604	0.602	0.610	0.606
随机森林	0.615	0.584	0.580	0.607	0.593
决策树	0.591	0.566	0.566	0.570	0.568




图2 三类模型样本外AUC比较

图形解读：三类模型AUC均高于0.5，说明预测排序优于随机。逻辑回归AUC最高，提示短样本下较简单的线性关系更稳定；随机森林次之，单棵决策树相对容易受到样本波动影响。

逻辑回归混淆矩阵为TN=3,778、FP=2,546、FN=2,468、TP=3,854。Precision与Recall均约0.60，说明模型对高收益类别的识别相对均衡，但仍有大量误判，不能把单只股票概率视为确定性结论。

5 基于模型的交易策略

每个测试季度按模型预测概率从高到低排序，选择前20%股票等权持有至下一季度末。组合收益使用缩尾后的个股简单价格收益均值，并按相邻组合权重变化计算换手率，扣除单边0.10%成本。基准为测试股票池全市场等权组合。

模型/基准	累计收益	年化波动	Sharpe	最大回撤	平均换手
逻辑回归	-3.0%	+3.6%	-1.10	-3.5%	+62%
随机森林	-5.9%	+3.2%	-2.44	-4.1%	+65%
决策树	-11.2%	+1.8%	-8.26	-7.6%	+88%
全市场等权	-19.8%	+8.1%	-3.14	-12.1%	+0%




图3 样本外季度策略收益

图形解读：测试期市场连续承压。逻辑回归在首期取得小幅正收益，后两期跌幅也显著小于基准；随机森林与决策树同样较基准减亏，但绝对收益仍为负。

6 回测净值、回撤与因子解释




图4 策略累计净值与回撤

图形解读：逻辑回归三季度累计收益约-3.0%、最大回撤约-3.5%，同期全市场等权累计约-19.8%、最大回撤约-12.1%。模型在该阶段体现出明显防御性，但负Sharpe也说明尚未形成稳定正向风险补偿。




图5 随机森林前10项重要特征

图形解读：随机森林主要依赖若干估值、成长与规模排名特征进行分裂。重要性表示样本内决策贡献，不代表因果关系，也可能在市场风格切换后发生变化。

7 分组检验、模型比较与结论




图6 随机森林预测概率五分组收益

图形解读：五分组检验关注预测概率从低到高是否形成单调收益差异。短测试期内分组存在区分度，但并非严格单调，提示模型信号较弱，仍需要更长历史和稳健性检验。

7.1 模型效果对比

逻辑回归在AUC、F1和策略累计收益上均领先，说明在本数据量与时间跨度下，正则化线性模型的稳定性优于复杂模型。随机森林分类表现居中，能够提供非线性特征重要性；决策树最易解释，但换手最高、策略收益最低。因此实际研究中可以逻辑回归作为基线，将随机森林用于非线性补充，而不宜仅依赖单棵树。

7.2 核心结论

本研究完成了从样本加载、特征衍生、目标设计、扩展窗口训练、概率选股到季度回测的完整链路。最优模型逻辑回归AUC为0.632，三季度累计收益-3.0%，相对全市场等权提升+16.8%。结果支持财务因子存在一定横截面排序信息，但不能据此声称长期盈利。

7.3 局限与改进方向

样本外仅3个季度，是本研究最重要的限制。后续应扩展至完整牛熊周期，使用前复权或总收益数据，按财务公告日对齐可得信息，并加入行业中性、市值中性、涨跌停、停牌、滑点与容量约束。还可采用时间序列交叉验证、参数稳定性分析和组合级风险预算，以提升结论的可信度与可交易性。

说明：本报告为课程教学研究，不构成任何投资建议。所有回测结果均基于历史数据和既定假设，历史表现不代表未来收益。